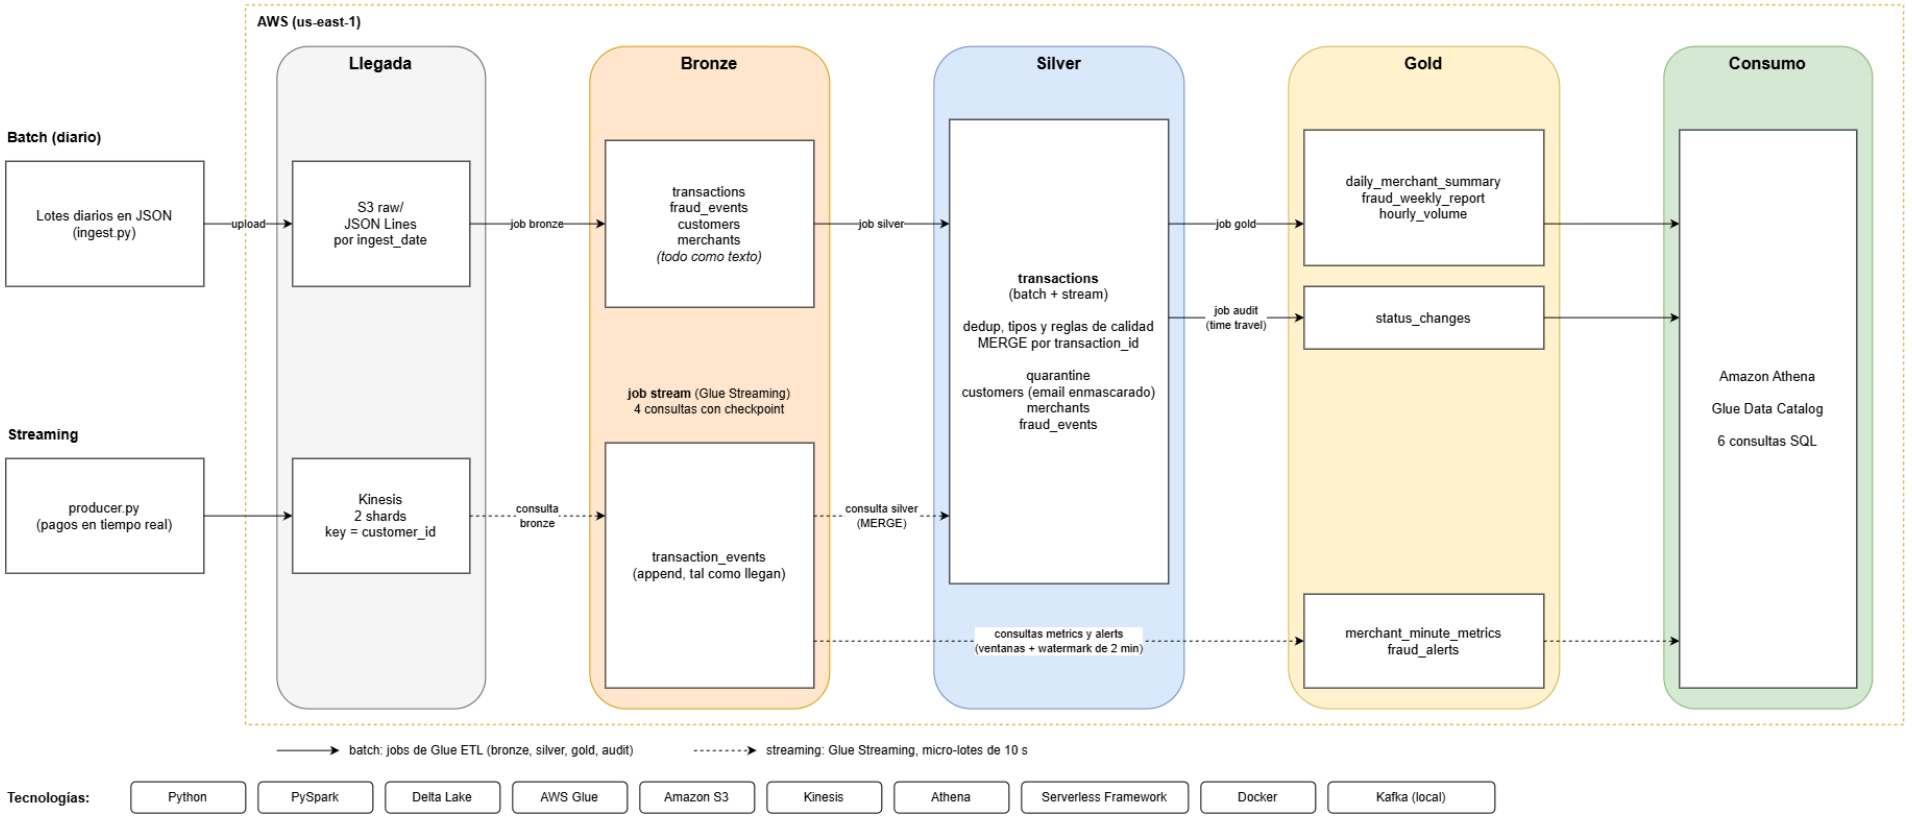
Laboratorio 2 · Capturas de ejecución

SI7006 · Almacenamiento y Procesamiento de Grandes Datos · EAFIT 2026-2

Estudiante: David Lopera Londoño

Diagrama de arquitectura

Arquitectura del lakehouse de PayTrack (Lab 2)



Parte A · Batch (local)

Figura 1. Generación de los lotes 1 y 2

```
(paytrack-bigdata-labs) PS C:\Users\user\Documents\semestre 2026-2\proc y alm de grandes volumenes de datos\big-data-
labs-2026-2> uv run python labs/shared/generate_data.py --start-date 2026-08-01 --days 60 --transactions 30000 --dirt
y-rate 0.02 --output data/batch1
Generando 500 clientes...
Generando 30000 transacciones...
Inyectando errores de calidad (2%)...
  ✓ data\batch1\customers.json (500 registros)
  ✓ data\batch1\merchants.json (8 registros)
  ✓ data\batch1\transactions.json (30600 registros)
  ✓ data\batch1\fraud_events.json (122 registros)

¡Listo! Datos generados en: data\batch1
(paytrack-bigdata-labs) PS C:\Users\user\Documents\semestre 2026-2\proc y alm de grandes volumenes de datos\big-data-
labs-2026-2> uv run python labs/shared/generate_data.py --start-date 2026-09-30 --days 1 --transactions 2000 --dirty-
rate 0.02 --from-batch data/batch1 --id-prefix B2 --output data/batch2
Reutilizando clientes de data\batch1 (con cambios de ciudad/segmento)...
Generando 2000 transacciones...
Inyectando errores de calidad (2%)...
Agregando 276 contracargos de transacciones del lote anterior...
  ✓ data\batch2\customers.json (500 registros)
  ✓ data\batch2\merchants.json (8 registros)
  ✓ data\batch2\transactions.json (2316 registros)
  ✓ data\batch2\fraud_events.json (11 registros)
```

Figura 2. Tests de ingest.py (7 passed)

```
Problems  Output  Debug Console  Terminal  Ports                                   powershell
labs-2026-2> uv run pytest labs/02-lakehouse/tests/test_ingest.py -v
(paytrack-bigdata-labs) PS C:\Users\user\Documents\semestre 2026-2\proc y alm de grandes volumenes de datos\big-data-
labs-2026-2>    uv run pytest "labs/Lab-02_David_Lopera_Londoño/tests/test_ingest.py" -v
============================================= test session starts =============================================
platform win32 -- Python 3.13.4, pytest-9.1.1, pluggy-1.7.0 -- C:\Users\user\Documents\semestre 2026-2\proc y alm de
grandes volumenes de datos\big-data-labs-2026-2\.venv\Scripts\python.exe
cachedir: .pytest_cache
rootdir: C:\Users\user\Documents\semestre 2026-2\proc y alm de grandes volumenes de datos\big-data-labs-2026-2
configfile: pyproject.toml
plugins: Faker-40.43.0, platformdirs-4.13.3, cov-7.1.0
collected 7 items

labs/Lab-02_David_Lopera_Londoño/tests/test_ingest.py::test_raw_prefix_formato_hive PASSED                  [ 14%]
labs/Lab-02_David_Lopera_Londoño/tests/test_ingest.py::test_raw_prefix_rechaza_fechas_invalidas[30-09-2026] PASSED [
28%]
labs/Lab-02_David_Lopera_Londoño/tests/test_ingest.py::test_raw_prefix_rechaza_fechas_invalidas[2026-13-01] PASSED [
42%]
labs/Lab-02_David_Lopera_Londoño/tests/test_ingest.py::test_raw_prefix_rechaza_fechas_invalidas[2026/09/30] PASSED [
57%]
labs/Lab-02_David_Lopera_Londoño/tests/test_ingest.py::test_raw_prefix_rechaza_fechas_invalidas[ayer] PASSED  [ 71%]
labs/Lab-02_David_Lopera_Londoño/tests/test_ingest.py::test_json_lines_un_objeto_por_linea PASSED            [ 85%]
labs/Lab-02_David_Lopera_Londoño/tests/test_ingest.py::test_json_lines_conserva_tildes PASSED                [100%]

============================================== 7 passed in 0.31s ==============================================
(paytrack-bigdata-labs) PS C:\Users\user\Documents\semestre 2026-2\proc y alm de grandes volumenes de datos\big-data-
labs-2026-2>
```

Figura 3. Bronze, lote 1

```
lopera@DESKTOP-9PFH6GN:/mnt/c/Users/user/Documents/semestre 2026-2/proc y alm de grandes volumenes de datos/big-data-labs-2026-2$ bash "labs/Lab-02_David_Lopera_Londoño/run_local.sh" data/batch1 2026-09-29 bronze

── bronze ──
✓ transactions: tiene las columnas de auditoría
✓ transactions: el lote 2026-09-29 tiene 30600 filas (sin duplicar)
✓ transactions: source_file apunta al archivo del lote
✓ fraud_events: tiene las columnas de auditoría
✓ fraud_events: el lote 2026-09-29 tiene 122 filas (sin duplicar)
✓ fraud_events: source_file apunta al archivo del lote
✓ customers: tiene las columnas de auditoría
✓ customers: el lote 2026-09-29 tiene 500 filas (sin duplicar)
✓ customers: source_file apunta al archivo del lote
✓ merchants: tiene las columnas de auditoría
✓ merchants: el lote 2026-09-29 tiene 8 filas (sin duplicar)
✓ merchants: source_file apunta al archivo del lote
```

Figura 4. Silver, lote 1

```
lopera@DESKTOP-9PFH6GN:/mnt/c/Users/user/Documents/semestre 2026-2/proc y alm de grandes volumenes de datos/big-data-labs-2026-2$ bash "labs/Lab-02_David_Lopera_Londoño/run_local.sh" data/batch1 2026-09-29 silver

── silver ──
✓ silver.transactions: tipos correctos
✓ lote: válidas + cuarentena = transacciones distintas del lote (no se perdió nada)
✓ cuarentena: cada fila tiene un dq_reason válido
✓ silver: sin transaction_id duplicados
✓ silver: se insertaron las 28239 transacciones nuevas
✓ silver: el status de cada transacción del lote quedó actualizado
✓ silver: todas las filas cumplen las reglas de calidad
✓ silver.customers: sin nombres y con emails enmascarados

Silver listo para el lote 2026-09-29
```

Figura 5. Gold

```
── gold ──
✓ daily: una fila por día y comercio
✓ daily: cuadra el número de transacciones con silver
✓ daily: cuadra el monto aprobado
✓ daily: cuadra el monto en contracargos
✓ daily: particiones bien formadas
✓ weekly: una fila por semana, patrón y segmento
✓ weekly: cuadra el número de eventos
✓ weekly: las semanas empiezan en lunes
✓ hourly: 24 horas
✓ hourly: cuadra con las aprobadas de silver

Gold listo
```

Figura 6. Auditoría del lote 2: 1.884 insertadas y 276 contracargos

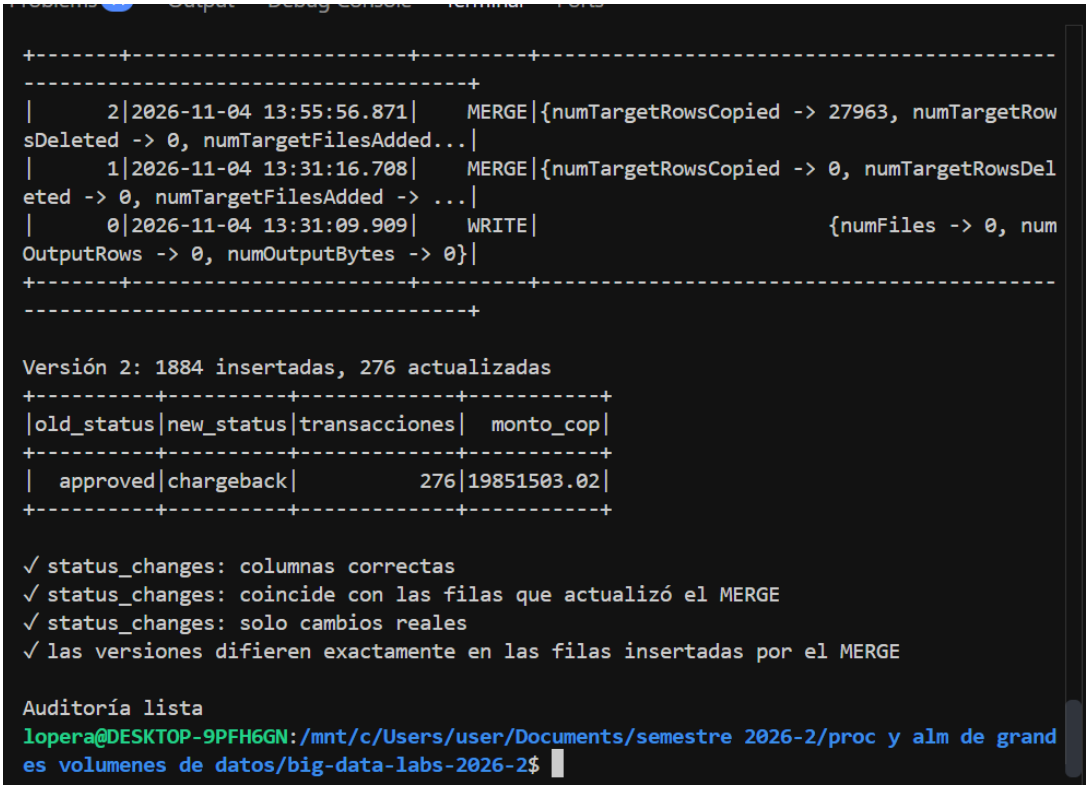
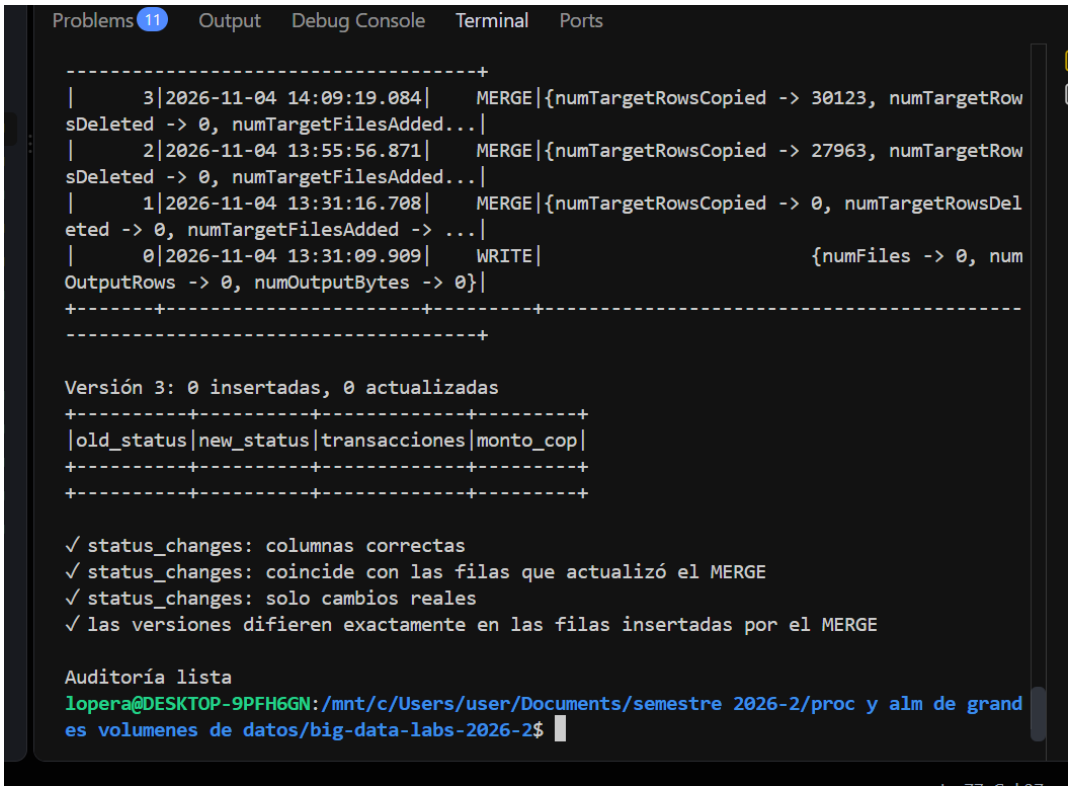


Figura 7. Auditoría de la re-ejecución del lote 2 (idempotencia): 0 insertadas y 0 actualizadas



Parte B · Streaming (local)

Figura 8. Tests de ingest.py y producer.py (15 passed)

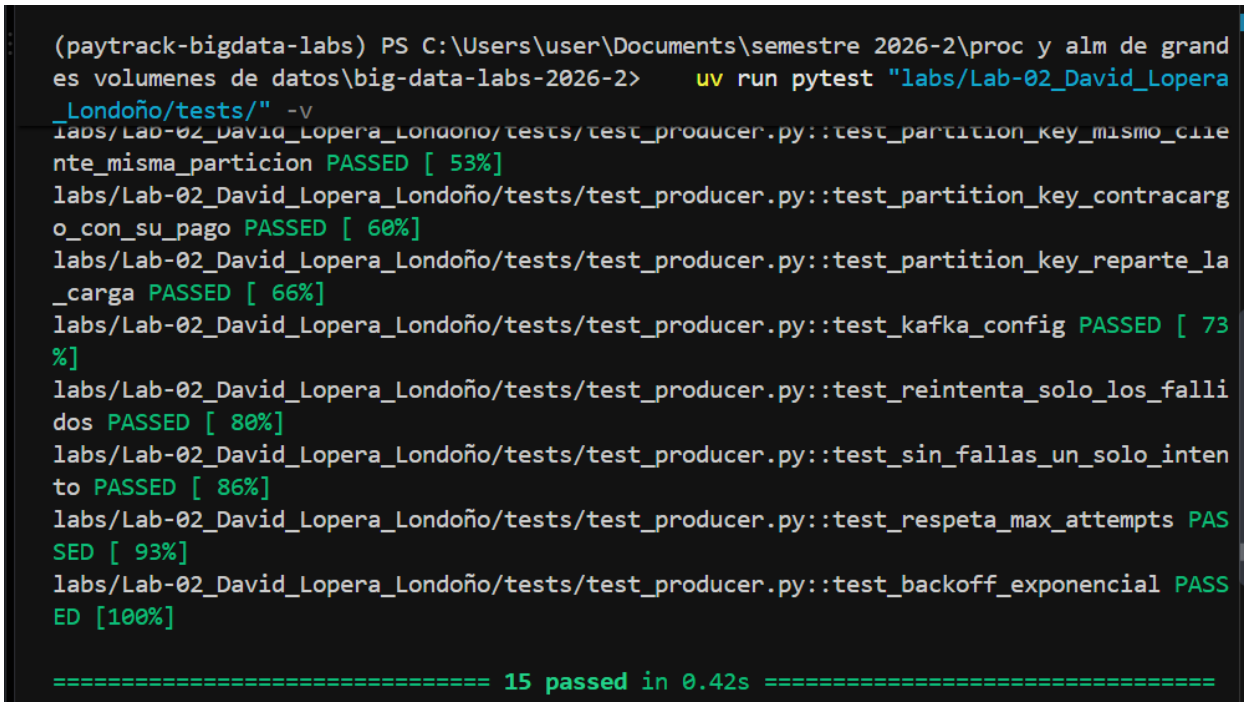


Figura 9. Kafka y productor: envío rápido (12.260 eventos) y en vivo (2.428 eventos)

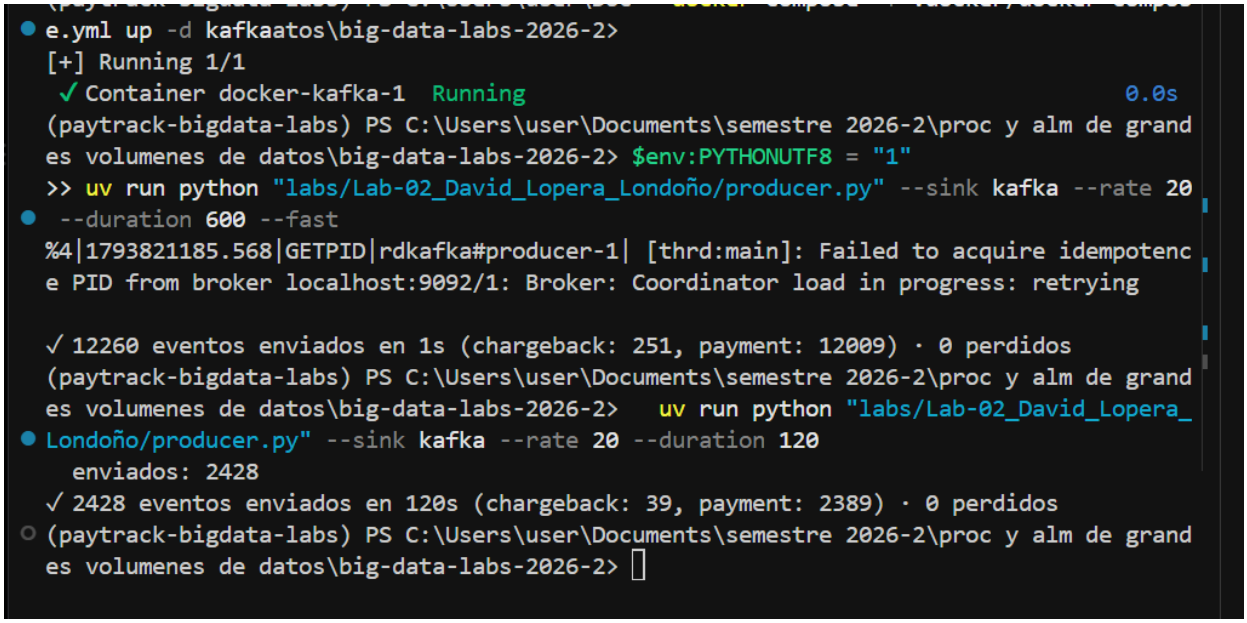
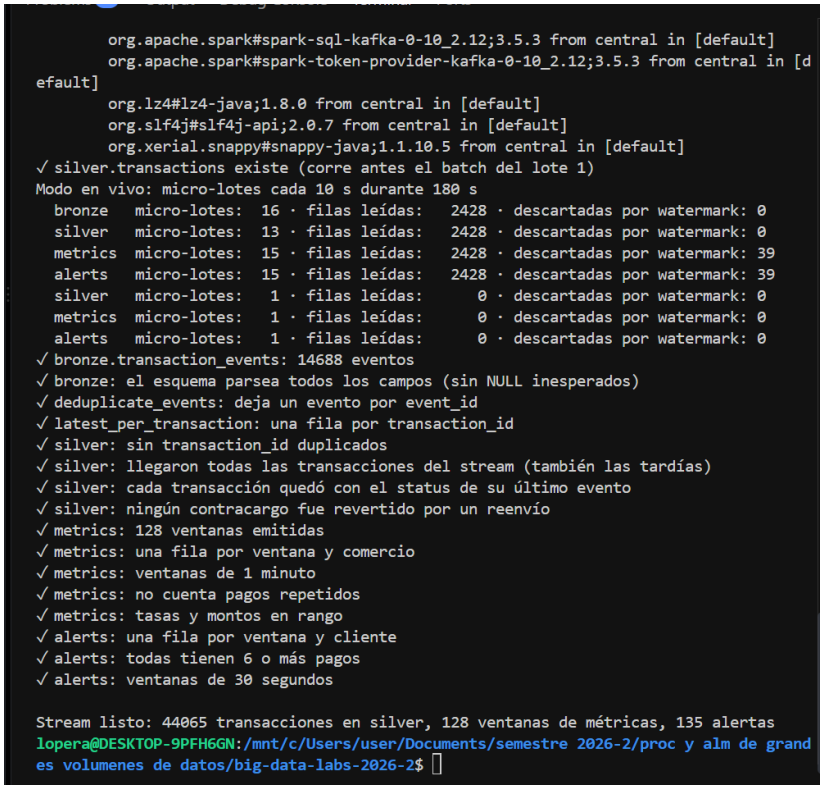


Figura 10. Job de streaming en vivo (180 s)



Ejecución en AWS

Figura 11. Despliegue de la infraestructura (serverless deploy)

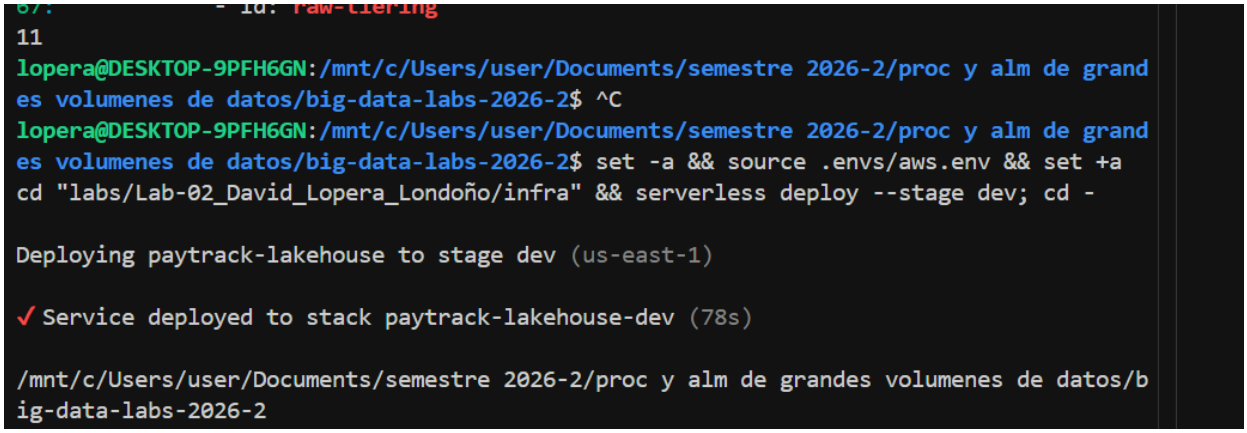


Figura 12. Pipeline batch en AWS, lote 1

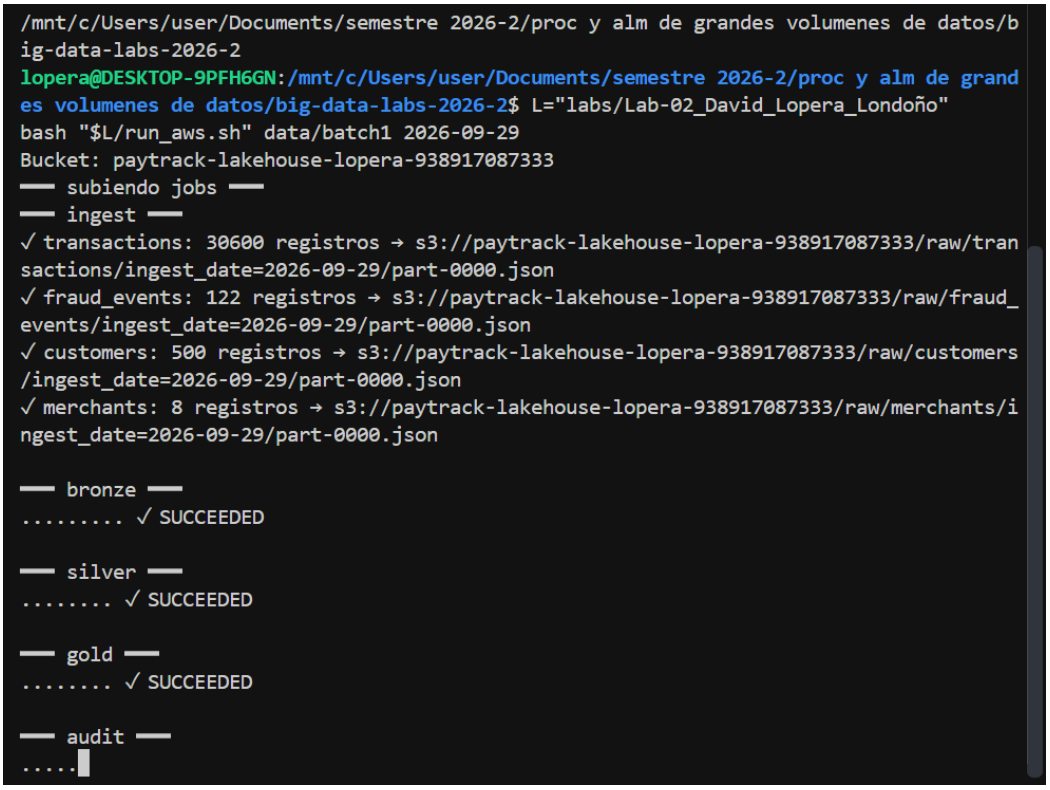


Figura 13. Pipeline batch en AWS, lote 2

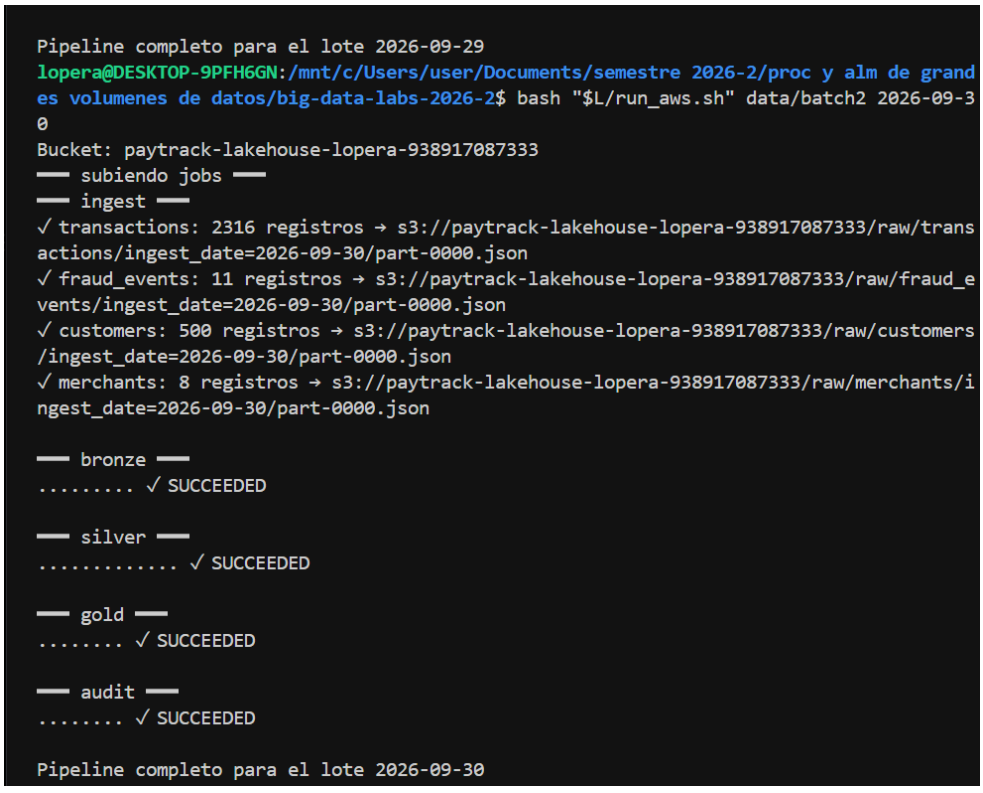


Figura 14. Streaming en AWS: productor a Kinesis y job de Glue Streaming

```
es volumenes de datos/big-data-labs-2026-2$ bash "$L/run_aws.sh" stream 300
Bucket: paytrack-lakehouse-lopera-938917087333
── subiendo jobs ──

── stream ──
Job paytrack-stream lanzado (jr_8e856e61b4855c35e0874bd63fcf2a9ac1e675b6adc7a0b0aeead8
98c965edb5). Glue tarda ~1 min en arrancar; Kinesis guarda
los eventos mientras tanto y el job los lee desde el más antiguo.
  enviados: 4882
✓ 4882 eventos enviados en 229s (chargeback: 96, payment: 4786) · 0 perdidos
Esperando a que el job termine (corre 300 s y luego valida)
.............. ✓ SUCCEEDED
lopera@DESKTOP-9PFH6GN:/mnt/c/Users/user/Documents/semestre 2026-2/proc y alm de grand
es volumenes de datos/big-data-labs-2026-2$
```

Figura 15. Jobs de Glue creados por el stack

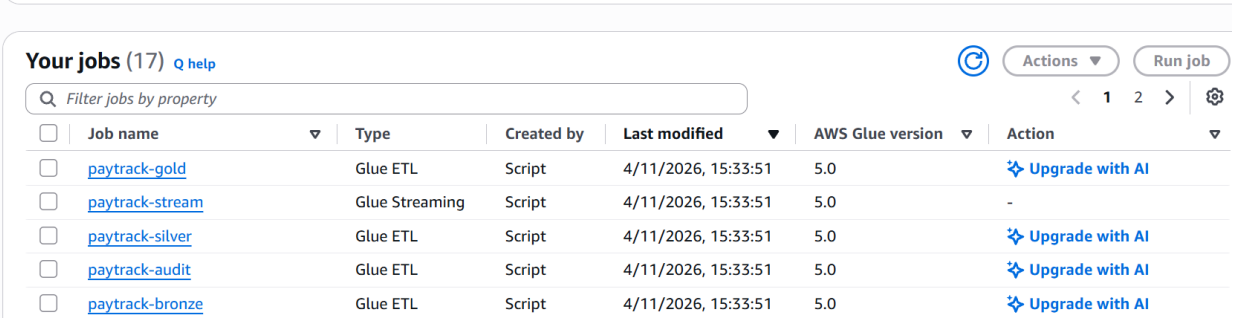


Figura 16. Ejecuciones del job paytrack-gold (Succeeded)

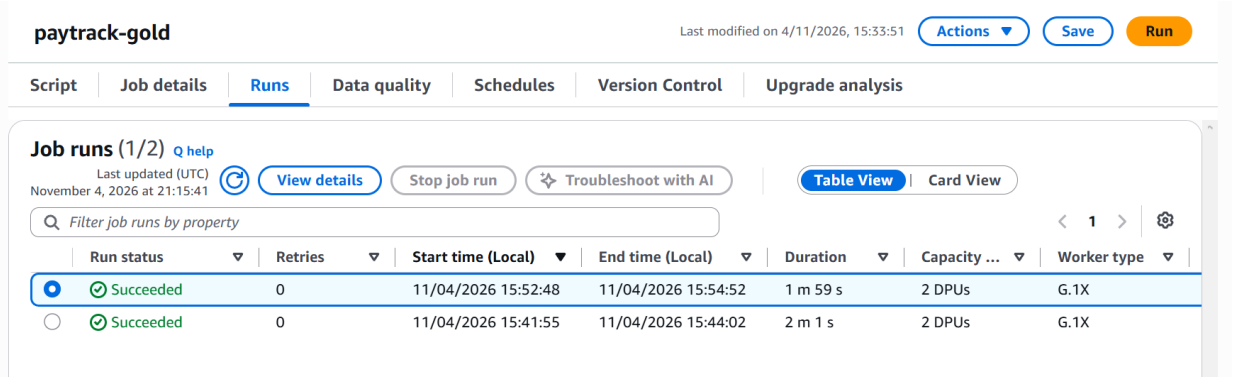


Figura 17. Ejecución del job paytrack-stream (Succeeded)

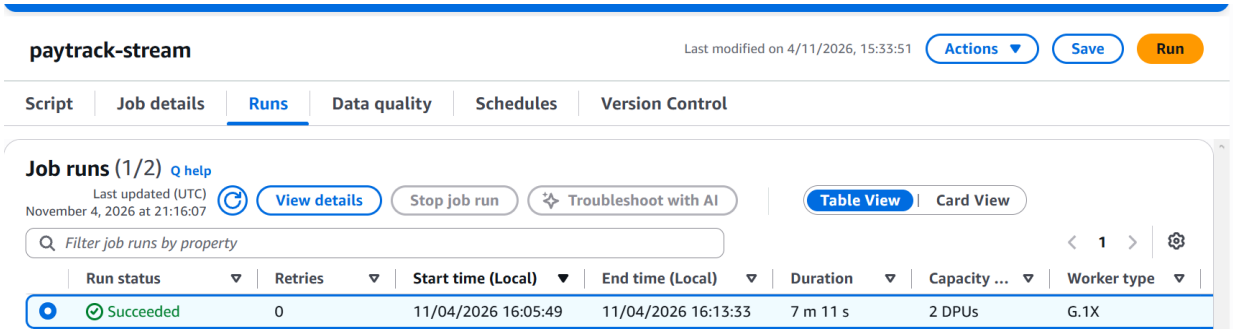


Figura 18. CloudWatch: validaciones del job de streaming

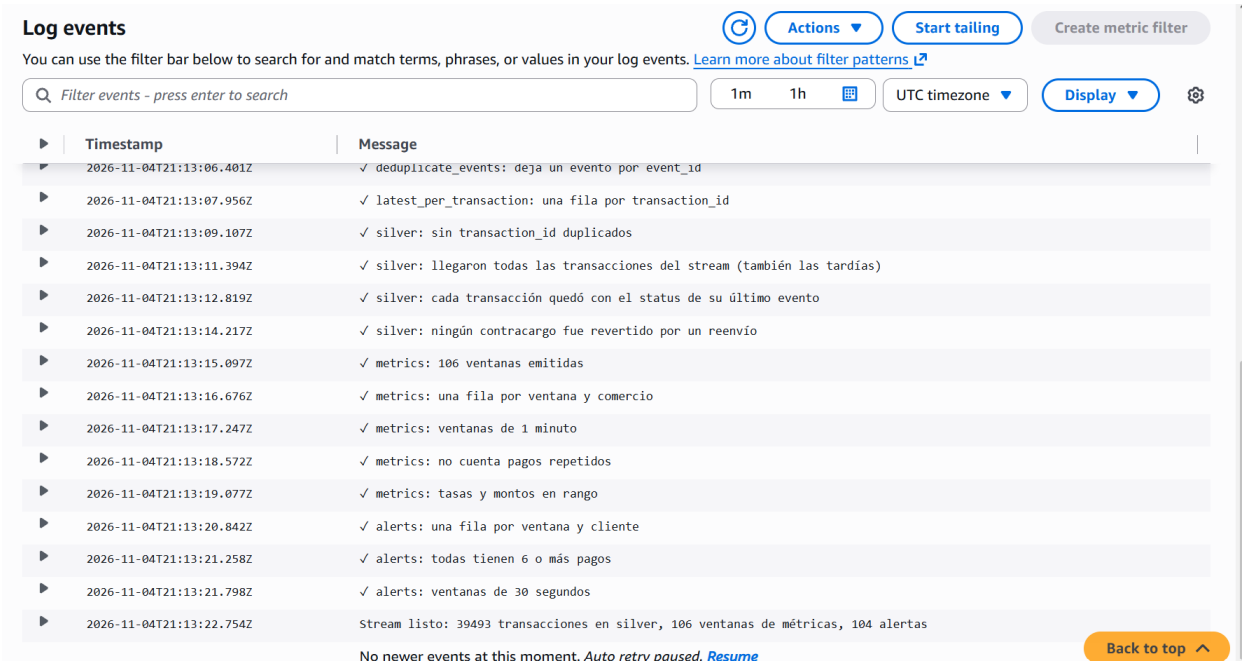
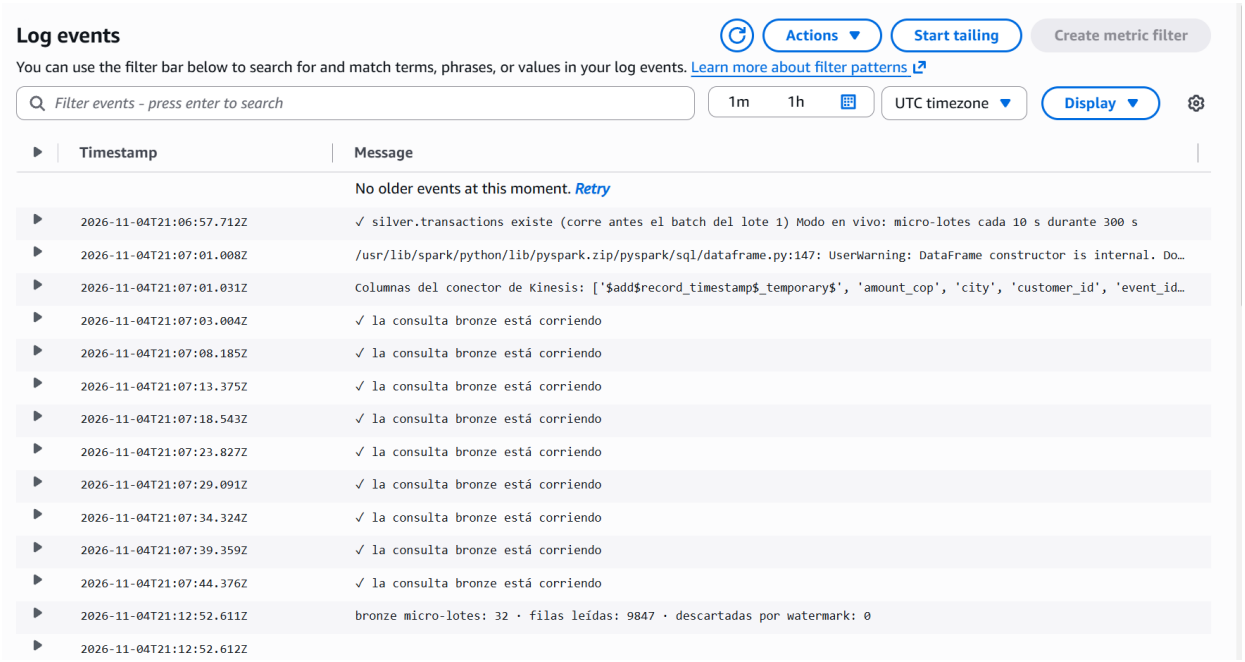
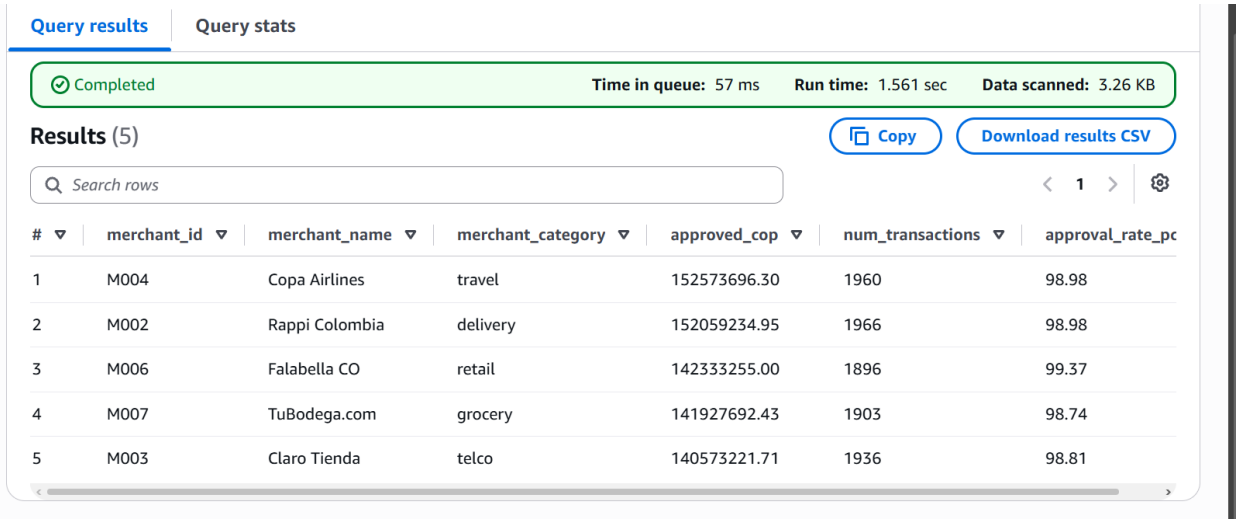


Figura 19. CloudWatch: columnas del conector de Kinesis y reporte de la consulta bronze



Consultas en Athena

Figura 20. TODO 1 · Top 5 de comercios desde Gold (antes de recalcular)



Query results | Query stats

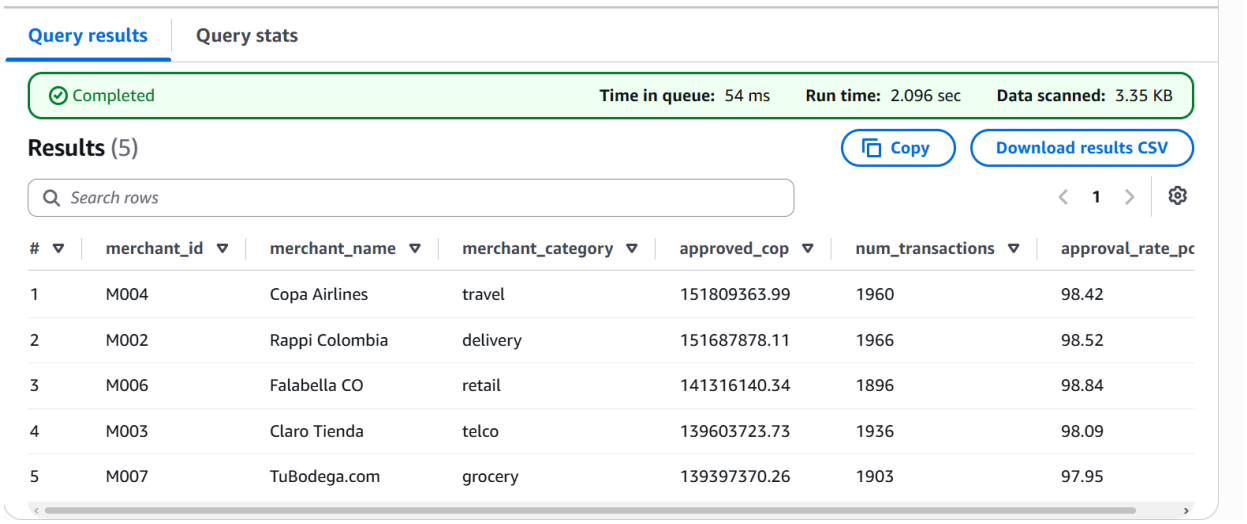
Completed — Time in queue: 57 ms — Run time: 1.561 sec — Data scanned: 3.26 KB

Results (5) — Copy — Download results CSV

Search rows — 1

#	merchant_id	merchant_name	merchant_category	approved_cop	num_transactions	approval_rate_pc
1	M004	Copa Airlines	travel	152573696.30	1960	98.98
2	M002	Rappi Colombia	delivery	152059234.95	1966	98.98
3	M006	Falabella CO	retail	142333255.00	1896	99.37
4	M007	TuBodega.com	grocery	141927692.43	1903	98.74
5	M003	Claro Tienda	telco	140573221.71	1936	98.81

Figura 21. TODO 1 · Top 5 de comercios desde Gold (recalculado)



Query results | Query stats

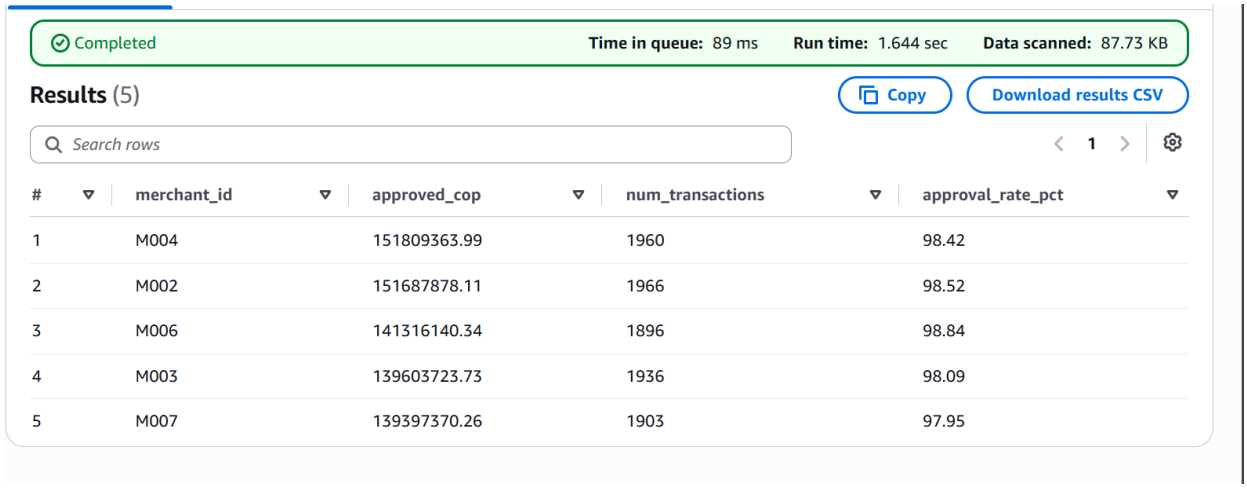
Completed — Time in queue: 54 ms — Run time: 2.096 sec — Data scanned: 3.35 KB

Results (5) — Copy — Download results CSV

Search rows — 1

#	merchant_id	merchant_name	merchant_category	approved_cop	num_transactions	approval_rate_pc
1	M004	Copa Airlines	travel	151809363.99	1960	98.42
2	M002	Rappi Colombia	delivery	151687878.11	1966	98.52
3	M006	Falabella CO	retail	141316140.34	1896	98.84
4	M003	Claro Tienda	telco	139603723.73	1936	98.09
5	M007	TuBodega.com	grocery	139397370.26	1903	97.95

Figura 22. TODO 2 · Top 5 de comercios desde Silver



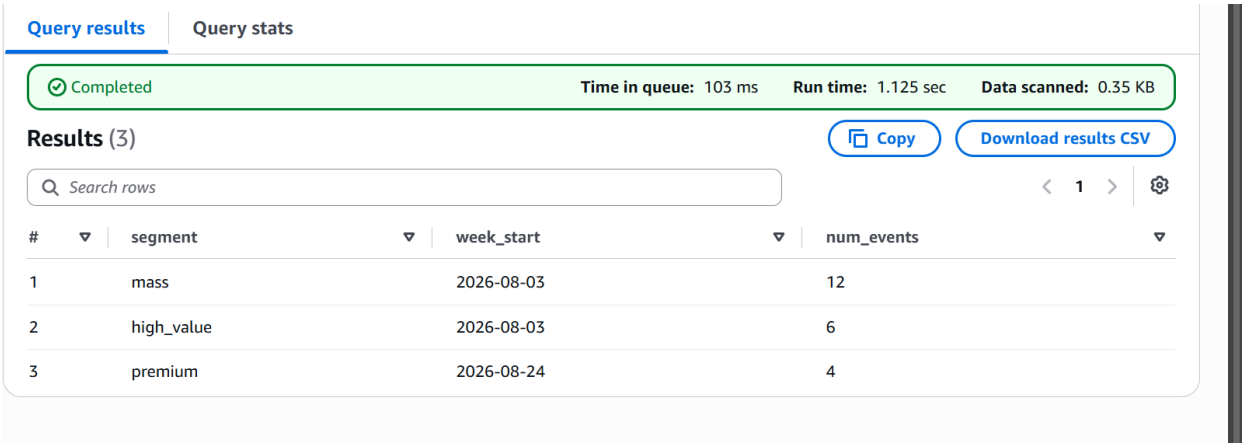
Completed — Time in queue: 89 ms — Run time: 1.644 sec — Data scanned: 87.73 KB

Results (5) — Copy — Download results CSV

Search rows — 1

#	merchant_id	approved_cop	num_transactions	approval_rate_pct
1	M004	151809363.99	1960	98.42
2	M002	151687878.11	1966	98.52
3	M006	141316140.34	1896	98.84
4	M003	139603723.73	1936	98.09
5	M007	139397370.26	1903	97.95

Figura 23. TODO 3 · Semana con más fraude por segmento



Query results | Query stats

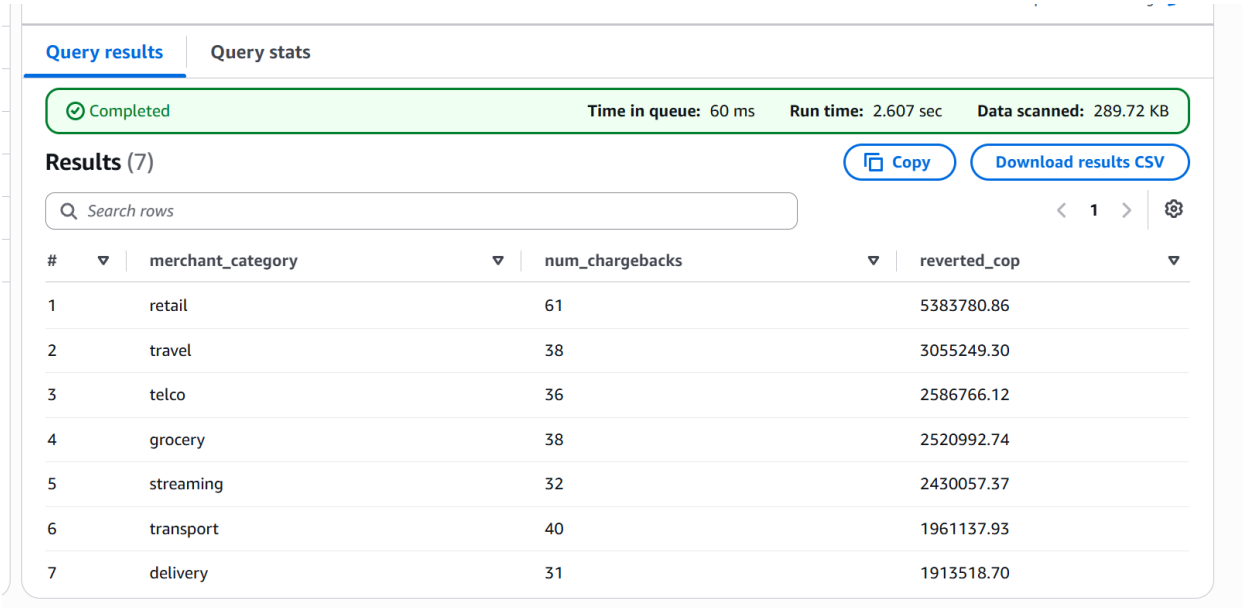
Completed — Time in queue: 103 ms — Run time: 1.125 sec — Data scanned: 0.35 KB

Results (3) — Copy — Download results CSV

Search rows — 1

#	segment	week_start	num_events
1	mass	2026-08-03	12
2	high_value	2026-08-03	6
3	premium	2026-08-24	4

Figura 24. TODO 4 · Contracargos por categoría de comercio



Query results | Query stats

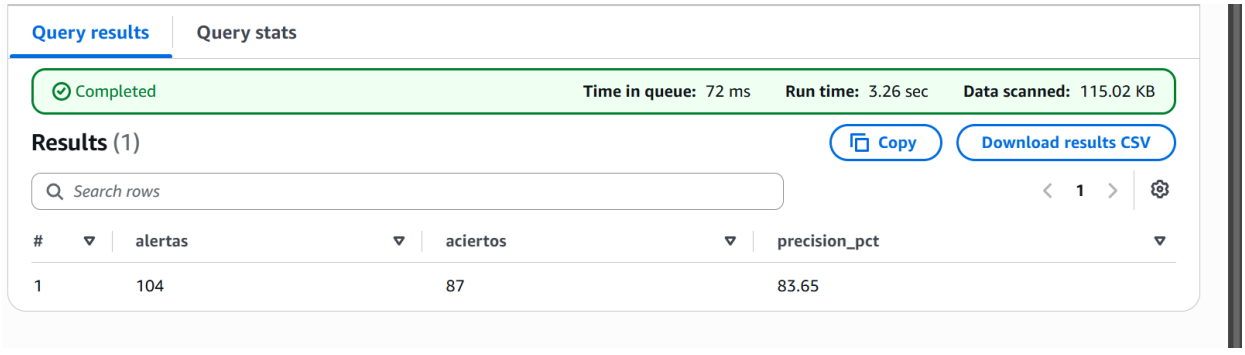
Completed — Time in queue: 60 ms — Run time: 2.607 sec — Data scanned: 289.72 KB

Results (7) — Copy — Download results CSV

Search rows — 1

#	merchant_category	num_chargebacks	reverted_cop
1	retail	61	5383780.86
2	travel	38	3055249.30
3	telco	36	2586766.12
4	grocery	38	2520992.74
5	streaming	32	2430057.37
6	transport	40	1961137.93
7	delivery	31	1913518.70

Figura 25. TODO 5 · Precisión de las alertas



Query results | Query stats

Completed — Time in queue: 72 ms — Run time: 3.26 sec — Data scanned: 115.02 KB

Results (1) — Copy — Download results CSV

Search rows — 1

#	alertas	aciertos	precision_pct
1	104	87	83.65

Figura 26. TODO 6 · Capa rápida vs. capa batch

